

Factorisations incomplètes de matrices creuses en précision mixte

De l'Analyse Exploratoire à l'Algorithme GEP Mixte

Radouane Aouini Sami Hbabou

Encadrant : Théo Mary (LIP6)

Cryptologie, Calcul haute-performance et Algorithmique (CCA) – Année Académique 2025-2026

20 mai 2026

Le Contexte : Solvers Iteratifs

- Résolution de $Ax = b$ pour des matrices A très grandes et creuses (milliers à millions de lignes).
- Les méthodes de sous-espace de Krylov (ex : **GMRES**) sont incontournables mais dépendent fortement du conditionnement de A .

Le Préconditionnement ILUT

- Approximation $A \approx LU = M$.
- Le seuil de chute (drop tolerance ε) élimine les éléments mineurs pour limiter le remplissage (*fill-in*).

Le goulot d'étranglement Mémoire

- ε strict $\implies$ Forte robustesse / peu d'itérations, mais explosion de la mémoire.
- ε lâche $\implies$ Faible mémoire, mais convergence lente ou divergence.
- **Inefficacité du FP64 uniforme** : Stocker tous les éléments proches de zéro en 64 bits est un gaspillage.

L'Approche Proposée : GEP Mixte

Objectif : Compresser drastiquement la taille mémoire du préconditionneur sans dégrader la convergence de GMRES.

Le concept GEP Mixte

Allouer dynamiquement et à la volée une précision spécifique (parmi 5 niveaux) à chaque élément individuel de la factorisation Incomplète LU en fonction de son impact numérique :

FP16 (Half)	FP24 (Custom)	FP32 (Single)	FP48 (Custom)	FP64 (Double)
16-bit	24-bit	32-bit	48-bit	64-bit
$u \approx 4.8 \times 10^{-4}$	$u \approx 1.5 \times 10^{-5}$	$u \approx 5.9 \times 10^{-8}$	$u \approx 1.4 \times 10^{-11}$	$u \approx 1.1 \times 10^{-16}$

Théorème (Local Dropping Bound)

Pour tout élément (i,j) supprimé lors de la factorisation ILUT (avec seuil ε), l'erreur locale introduite satisfait :

$$|E_{ij}| \leq \varepsilon \|A_{\cdot j}\|_2$$

Démonstration (Esquisse pour U ($i \leq j$)) :

- Soit $v_{ij} = a_{ij} - \sum_{k=1}^{i-1} \hat{l}_{ik} \hat{u}_{kj}$ la valeur calculée avant le drop.
- L'algorithme fixe $\hat{u}_{ij} = 0$ ssi $|v_{ij}| \leq \varepsilon \|A_{\cdot j}\|_2$.
- L'erreur vaut :

$$E_{ij} = (\hat{L}\hat{U})_{ij} - a_{ij} = -v_{ij}$$

- D'où directement : $|E_{ij}| \leq \varepsilon \|A_{\cdot j}\|_2$.


Implication fondamentale :

- Puisque l'on accepte déjà une erreur locale de $\varepsilon \|A_{\cdot j}\|_2$ en supprimant des coefficients, on peut tolérer une erreur d'arrondi de représentation du même ordre sur les coefficients conservés !
- **C'est le budget d'erreur de la colonne j .**

Phase 1 : Influence du Seuil de Chute sur la Convergence

Observations sur la matrice *bcsstk08* :

- Un seuil très lâche ($\varepsilon = 0.2$) nécessite **53 itérations** GMRES pour converger.
- Un seuil très strict ($\varepsilon = 10^{-4}$) converge extrêmement vite en seulement **10 itérations**.
- La baisse du résidu est monotone mais le nombre d'itérations chute drastiquement avec l'augmentation de la qualité du préconditionneur.




Phase 1 : Compromis Itérations / Fill-in et Optimisation

Le Dilemme Classique :



- À $\varepsilon = 10^{-5}$: fill-in géant ($\approx 26\times$ plus d'éléments que la matrice originale).
- À $\varepsilon = 10^{-2}$: fill-in proche de 1.0 mais convergence plus lente.

Optimisation dichotomique (Ternaire) :

- Minimisation de $J(\varepsilon) = \text{Time}_{\text{factorisation}}(\varepsilon) + (\text{Fill-in} \times \text{Iter})$.
- Recherche en $O(\log(1/\text{tol}))$.
- Optimum localisé à $\varepsilon \approx 1.75 \times 10^{-2}$ (fill-in = 0.90).



Phase 1 : Instabilité d'une Précision Faible Uniforme



- **FP16 Uniforme (ligne jaune à 0) :**
Divergence complète sur toute la plage de tolérance stricte !

Conclusion de la Phase 1 : Stocker tout en basse précision détruit le préconditionneur. Un choix sélectif et adaptatif est indispensable.

- **Historique à $\varepsilon = 10^{-5}$:** Le FP32 suit le FP64, mais le FP16 diverge instantanément (zéro point).

Phase 2 : Le Critère de Précision GEP Mixte

Modèle d'Erreur d'Arrondi

Un élément conservé x_{ij} stocké dans un format de précision μ_{ij} introduit une erreur locale

$$E_{ij}^{\text{round}} \leq |x_{ij}| \mu_{ij}.$$

Pour assurer que cette erreur ne dépasse pas le budget d'erreur déjà toléré par la colonne j ($\varepsilon \|A_{\cdot,j}\|_2$), on déduit la contrainte suivante :

Pour U ($i \leq j$) : Entrées Directes

$$\begin{aligned} |E_{ij}^{\text{round}}| &\leq |u_{ij}| \mu_{ij} \leq \varepsilon \|A_{\cdot,j}\|_2 \\ \implies \mu_{ij} &\leq \frac{\varepsilon \|A_{\cdot,j}\|_2}{|u_{ij}|} \end{aligned}$$

Pour L ($i > j$) : Multiplicateurs amplifiés par le pivot

$$\begin{aligned} |E_{ij}^{\text{round}}| &\leq |l_{ij} u_{jj}| \mu_{ij} \leq \varepsilon \|A_{\cdot,j}\|_2 \\ \implies \mu_{ij} &\leq \frac{\varepsilon \|A_{\cdot,j}\|_2}{|l_{ij} u_{jj}|} \end{aligned}$$

Propriété clé : Si l'élément est grand ou si le pivot u_{jj} est grand $\implies \mu_{ij}$ doit être très petit (FP64 requis). Si l'élément est proche du seuil $\implies \mu_{ij}$ grand (FP16 autorisé).

L'Algorithme :

- 1 Durant l'élimination de Gauss, pour chaque coefficient calculé au-dessus du seuil $\varepsilon \|A_{\cdot j}\|_2$, on calcule sa cible τ_{ij} .
- 2 On lui attribue le format matériel le plus économique vérifiant $\mu_{ij} \leq \tau_{ij}$:

Cible $\tau_{ij} \geq u_{16} \implies \mathbf{FP16 (Half)}$

$u_{16} > \tau_{ij} \geq u_{24} \implies \mathbf{FP24}$

$u_{24} > \tau_{ij} \geq u_{32} \implies \mathbf{FP32}$

$u_{32} > \tau_{ij} \geq u_{48} \implies \mathbf{FP48}$

$u_{48} > \tau_{ij} \implies \mathbf{FP64 (Double)}$



Complexité arithmétique additionnelle

- **Normes des colonnes** : Calculées 1 fois au départ $\implies 2 \operatorname{nnz}(A)$ ops.
- **Évaluation par élément** :
 - Pour U : 1 division.
 - Pour L : 1 multiplication + 1 division.
- **Coût global** : $O(\operatorname{nnz}(L) + \operatorname{nnz}(U))$, soit seulement 1 à 2 flops supplémentaires par élément stocké.
- **Totalement négligeable** devant le coût $O(n^3)$ de la factorisation ou de GMRES !

Résultats : Robustesse spectrale et Remplissage

Observations :


- **Gauche (Itérations)** : GEP Mixte (courbe bleue) se superpose parfaitement aux itérations du FP64 de référence. Il n'y a **aucune perte de convergence**, contrairement au FP16 uniforme qui diverge.
- **Droite (Fill-in)** : Le facteur de remplissage est rigoureusement identique. La sélection du format intervient après le dropping arithmétique, préservant le profil de creux de la matrice.



Résultats : Allocation Dynamique des Formats

Analyse physique de l'allocation :


- **Aux tolérances strictes ($\leq 10^{-4}$)** : Plus de **90% des éléments** sont alloués en **FP16** ! Seuls les pivots et quelques éléments critiques sont en **FP24**.
- **Aux tolérances lâches ($\geq 10^{-1}$)** : Le FP16 chute à 19% et le **FP24 domine à 81%**.
- **Pourquoi ?** À 10^{-1} , seuls les pivots géants sont conservés. Étant très grands, ils demandent une précision stricte (μ_{ij} petit), forçant le passage en FP24 pour éviter des erreurs catastrophiques sur les pivots.




Résultats : Compression de l'Empreinte Mémoire

Analyse de la taille mémoire (KB) :

- Régime optimal ($\varepsilon = 10^{-5}$) :
 - Stockage Standard FP64 : **2640 KB**.
 - Stockage GEP Mixte : **700 KB**.
 - Facteur de compression : **$3.8\times$** !
- GEP Mixte colle à l'encombrement du FP16 pur pour les tolérances courantes, tout en évitant sa divergence.
- Permet de charger des préconditionneurs de très grande taille en mémoire vive limitée.




Résultats : Profil de Performance Dolan-Moré – Mémoire





- **Profil Global (avec ILU(0))** : GEP Mixte (bleu) domine largement tous les solvers robustes en efficacité mémoire.

GEP Mixte atteint $\rho = 1.0$ à $\tau \approx 1.3$ (à peine 30% plus lourd que le FP16 brut), garantissant robustesse et compacité.



- **Profil sans ILU(0)** : À $\tau = 1$, GEP Mixte partage la tête avec FP16. Mais FP16 stagne à 0.50 (divergence sur 3/6 matrices), tandis que GEP Mixte résout **100% des cas**.

Résultats : Profil de Performance Dolan-Moré – Itérations



- GEP Mixte (bleu) offre exactement la même robustesse face aux itérations que les solvers double précision (FP64).

La perte d'information liée à la compression est numériquement indétectable par le solveur GMRES.

- GEP Mixte atteint $\rho = 1.0$ à $\tau \approx 1.09$. Soit au pire un surcoût d'itérations de seulement **9%** sur une seule matrice, et **0% d'écart sur les 5 autres**.

Principaux acquis de l'étude

- ❶ **Critère de précision constructif** reliant rigoureusement l'erreur d'arrondi locale au budget de dropping de la colonne, avec gestion de l'amplification par les pivots.
- ❷ **Forte compression mémoire de $3.8\times$** par rapport au FP64 uniforme.
- ❸ **Robustesse mathématique absolue (100% de convergence)** préservée sur des cas d'ingénierie difficiles (SuiteSparse), là où la précision basse uniforme échoue.
- ❹ **Zéro surcoût arithmétique réel** lors de la factorisation ($O(\text{nnz})$ additionnel).

Limitations actuelles :

- Utilisation de structures denses pour la factorisation active.
- Les formats personnalisés (FP24, FP48) sont simulés de manière logicielle.

Travaux futurs :

- Co-design matériel : Implémenter GEP Mixte sur puces dédiées (FPGA/ASIC custom bit-width).
- Intégration en structures creuses compressées natives.